

Métodos Numéricos para Engenharia

MÓDULO 9 - ALGEBRA LINEAR NUMERICA – JACOBI - SEIDEL

PROFESSOR LUCIANO NEVES DA FONSECA

Problema $Ax = b$ Bem-Condicionado

Um problema $Ax = b$ é considerado **Bem-Condicionado** quando apresenta uma Solução Única


$$A = \begin{bmatrix} 3 & 2 \\ -1 & 2 \end{bmatrix}$$

$$b = \begin{bmatrix} 18 \\ 2 \end{bmatrix}$$

```
--> plotimplicit("3*x+2*y=18",0:10,0:9,'b')  
--> plotimplicit("-x+2*y=2",0:10,0:9,'r')
```

```
--> A=[3,2;-1,2]  
    3.    2.  
   -1.    2.  
--> b=[18;2]  
    18.  
     2.  
--> x=inv(A)*b  
    4.  
    3.
```

```
--> det(A)  
ans =  
    8.
```



Condições Necessárias para uma solução única.

- ▶ O número de equações deve ser igual ao número de incógnitas, isto é, o número de linhas deve ser igual ao número de colunas da matriz A.
- ▶ Todas as equações devem ser linearmente independentes. Nenhuma linha pode ser uma combinação linear de outras linhas.
- ▶ O Determinante da Matriz Característica (A) não pode ser nulo.
- ▶ Um determinante característico (determinante da matriz a) muito pequeno pode causar erros de arredondamento e instabilidade na solução.

Um problema $Ax = b$ é considerado Mal-Condicionado quando apresenta infinitas soluções ou quando não apresenta soluções.

- 1) Determinante Nulo – Equações idênticas
infinitas soluções


$$A = \begin{bmatrix} -1 & 1 \\ -2 & 2 \end{bmatrix}$$

$$b = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

```
--> plotimplicit("-2*x+2*y=2",0:10,0:9,'b')  
--> plotimplicit("-2*x+2*y=2",0:10,0:9,'r')
```

```
--> A=[-1,1;-2,2];  
--> b=[1;2];  
--> x=inv(A)*b  
inv: Problem is singular.
```

```
--> det(A)  
ans =  
  
0.
```



- 2) Determinante Nulo – Equações Paralelas
não há solução


$$A = \begin{bmatrix} -1 & 1 \\ -2 & 2 \end{bmatrix}$$

$$b = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

```
--> plotimplicit("-x+y=1",0:10,0:9,'b')  
--> plotimplicit("-2*x+2*y=-2",0:10,0:9,'r')
```

```
--> A=[-1,1;-2,2];  
--> b=[1;-2];  
--> x=inv(A)*b  
inv: Problem is singular.
```

```
--> det(A)  
ans =  
  
0.
```



3) Determinante de A muito pequeno

- Equações com inclinações muito próximas, causando erros de arredondamento.

- Solução única mal definida


- Notar que pequenas mudanças nos coeficientes de [A] ou [b] alteram significativamente o resultado final x

$$A = \begin{bmatrix} -1.01 & 1 \\ -1 & 1 \end{bmatrix} \quad b = \begin{bmatrix} -1.05 \\ -1 \end{bmatrix}$$

```
--> A=[-1.01,1;-1,1];  
--> det(A)  
-0.010000000  
--> b=[-1.05;-1];  
--> x=inv(A)*b  
5.  
4.
```

```
--> plotimplicit("-1.01*x+y=-1.05",0:10,0:10,'b')  
--> plotimplicit("-1*x+y=-1",0:10,0:10,'r')
```

$$-1 \cdot x + 1 \cdot y = -1$$




$$A = \begin{bmatrix} -1.01 & 1 \\ -1 & 1 \end{bmatrix} \quad b = \begin{bmatrix} -1.05 \\ -1.01 \end{bmatrix}$$

```
--> A=[-1.01,1;-1,1];  
--> det(A)  
-0.010000000  
--> b=[-1.05;-1.01];  
--> x=inv(A)*b  
4.  
2.99
```

```
--> plotimplicit("-1.01*x+y=-1.05",0:10,0:10,'b')  
--> plotimplicit("-1*x+y=-1.01",0:10,0:10,'r')
```

$$-1 \cdot x + 1 \cdot y = -1.01$$




$$A = \begin{bmatrix} -1.01 & 1 \\ -1 & 1.01 \end{bmatrix} \quad b = \begin{bmatrix} -1.05 \\ -1 \end{bmatrix}$$

```
--> A=[-1.01,1;-1,1.01];  
--> det(A)  
-0.020100000  
--> b=[-1.05;-1];  
--> x=inv(A)*b  
3.009950249  
1.990049751
```

```
--> plotimplicit("-1.01*x+y=-1.05",0:10,0:10,'b')  
--> plotimplicit("-1*x+1.01*y=-1",0:10,0:10,'r')
```

$$-1 \cdot x + 1.01 \cdot y = -1$$



4) Det(A) muito grande $A^{-1}A$ muito diferente da Matriz identidade I

```
--> A=testmatrix('hilb',7)
A =

    49.    -1176.    8820.   -29400.    48510.   -38808.    12012.
   -1176.    37632.   -317520.    1128960.   -1940400.    1596672.   -504504.
    8820.   -317520.    2857680.   -10584000.    18711000.   -15717240.    5045040.
   -29400.    1128960.   -10584000.    40320000.   -72765000.    62092800.   -20180160.
    48510.   -1940400.    18711000.   -72765000.    1.334D+08   -1.153D+08    37837800.
   -38808.    1596672.   -15717240.    62092800.   -1.153D+08    1.006D+08   -33297264.
    12012.   -504504.    5045040.   -20180160.    37837800.   -33297264.    11099088.

--> det_gauss(A,%F)
ans =

    2.068D+24

--> inv_gauss(A,%F)*A
ans =

    1.    -5.053D-11    4.471D-10   -1.323D-09    4.343D-09   -2.928D-09    3.550D-10
    1.728D-12    1.    7.721D-10   -2.157D-09    4.103D-09   -3.908D-09    2.234D-09
    1.494D-13    3.101D-11    1.    3.674D-10   -1.650D-10    1.188D-09   -8.566D-11
    6.236D-13   -1.664D-11    2.090D-11    1.    1.234D-09    8.516D-10    3.370D-10
    5.451D-14   -2.048D-11   -1.348D-11    5.394D-11    1.    7.293D-10   -5.535D-10
    7.589D-13   -2.255D-11    2.255D-10   -9.020D-10    1.517D-09    1.    1.469D-10
   -7.866D-14    2.849D-12    4.427D-11   -1.771D-10    3.320D-10   -7.578D-10    1.
```

Detectamos que a Matriz Característica A está mal condicionada, por o seu determinante ser muito grande ($2.068 \cdot 10^{24}$) e por $A^{-1}A \neq I$ (quadro acima)

No quadro da direita, vemos que na resolução do sistema, a mudança de um único elemento $A(1,1)$ de 49 para 50, alterou de maneira significativa a solução.

```
--> A
A =

    49.    -1176.    8820.   -29400.    48510.   -38808.    12012.
   -1176.    37632.   -317520.    1128960.   -1940400.    1596672.   -504504.
    8820.   -317520.    2857680.   -10584000.    18711000.   -15717240.    5045040.
   -29400.    1128960.   -10584000.    40320000.   -72765000.    62092800.   -20180160.
    48510.   -1940400.    18711000.   -72765000.    133402500.   -115259760.    37837800.
   -38808.    1596672.   -15717240.    62092800.   -115259760.    100590336.   -33297264.
    12012.   -504504.    5045040.   -20180160.    37837800.   -33297264.    11099088.

--> b=[1;2;3;4;5;6;7];

--> inv(A)*b
Warning :
matrix is close to singular or badly scaled. rcond = 1.0150E-09
ans =

    7.
    5.282142857
    4.342063492
    3.713095238
    3.253823954
    2.900613276
    2.619197469

--> A(1,1)=50
A =

    50.    -1176.    8820.   -29400.    48510.   -38808.    12012.
   -1176.    37632.   -317520.    1128960.   -1940400.    1596672.   -504504.
    8820.   -317520.    2857680.   -10584000.    18711000.   -15717240.    5045040.
   -29400.    1128960.   -10584000.    40320000.   -72765000.    62092800.   -20180160.
    48510.   -1940400.    18711000.   -72765000.    133402500.   -115259760.    37837800.
   -38808.    1596672.   -15717240.    62092800.   -115259760.    100590336.   -33297264.
    12012.   -504504.    5045040.   -20180160.    37837800.   -33297264.    11099088.

--> inv(A)*b
Warning :
matrix is close to singular or badly scaled. rcond = 2.0301E-09
ans =

    3.5
    3.532142857
    3.175396825
    2.838095238
    2.553823954
    2.317279942
    2.119197469
```


1) Métodos Iterativos - Gauss Jacobi

Neste método, consideramos que cada uma das linhas do nosso sistema de equações $Ax=b$ é, na verdade, uma equação para a qual queremos encontrar a raiz.

Para o cálculo das raízes usamos exatamente o método do Ponto Fixo, aplicado a cada uma das linhas.

Como o método é iterativo, começamos com uma vetor solução inicial x^0 qualquer e calculamos a solução x^1 , com a solução x^k calculamos a solução x^{k+1} e assim iterativamente, parando quando o erro relativo entre soluções subsequentes for menor que uma certa tolerância.

$$a_{11}x_1 + a_{12}x_2 + a_{13}x_3 = b_1$$

$$a_{21}x_1 + a_{22}x_2 + a_{23}x_3 = b_2$$

$$a_{31}x_1 + a_{32}x_2 + a_{33}x_3 = b_3$$

Isolando uma variável por linha temos:

$$x_1^{k+1} = \frac{1}{a_{11}}(b_1 - a_{12}x_2^k - a_{13}x_3^k)$$

$$x_2^{k+1} = \frac{1}{a_{22}}(b_2 - a_{21}x_1^k - a_{23}x_3^k)$$

$$x_3^{k+1} = \frac{1}{a_{33}}(b_3 - a_{31}x_1^k - a_{32}x_2^k)$$

```
1 function x0=GaussJacobi(A,b,x_ini,tol,prt)
2     N=length(b);
3     erro=-1;
4     x0=x_ini
5     sol(:,1)=x0
6     erro_vector(1,1)=erro
7     for k=2:500
8         for j=1:N
9             x1(j)=(b(j)-A(j,:)*x0+A(j,j)*x0(j))/A(j,j);
10        end
11        if(norm(x1)<>0) erro=norm(x1-x0)/norm(x1) end
12        x0=x1;
13        sol(:,k)=x0
14        erro_vector(1,k)=erro
15        if erro<tol break end
16    end
17    :
18    :
24 endfunction
```

Algoritmo para o Método Iterativo de Gauss Jacobi

```
--> A=[8,2,4;1,11,3;5,3,10]
A =

    8.    2.    4.
    1.   11.    3.
    5.    3.   10.

--> b=[9;18;72];

--> x=inv(A)*b
x =

   -3.2311475
   -0.5163934
    8.9704918
```

```
--> x=GaussJacobi(A,b,[0;0;0],1e-6,%T)

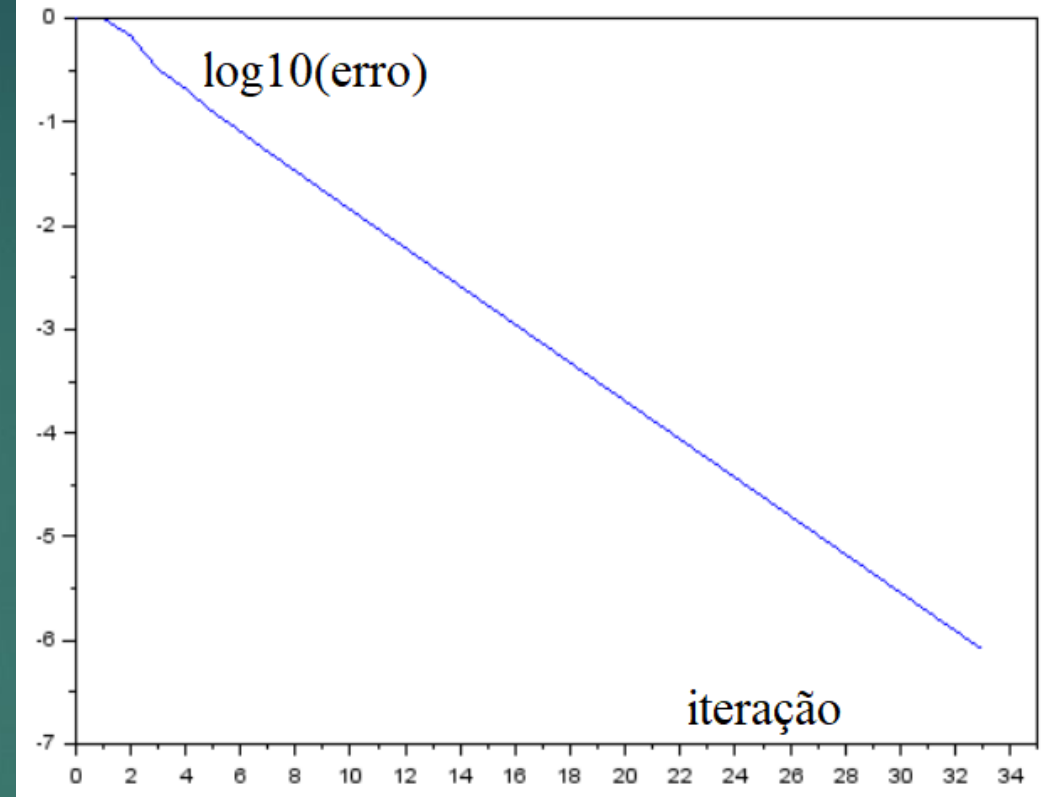
    8.    2.    4.    9.
    1.   11.    3.   18.
    5.    3.   10.   72.

"erro"
"x(1)"
"x(2)"
"x(3)"

    column 1 to 6
    1.    1.          0.6807807    0.3232971    0.2095781    0.124572
    0.    1.125      -2.8840909   -1.8409091   -3.3160072   -2.7548089
    0.    1.6363636   -0.4295455    0.2222107   -0.5883471   -0.2586697
    0.    7.2         6.1465909    8.7709091    8.0537913    9.0345077
    column 7 to 12
    0.0815145    0.051581    0.0337982    0.021842    0.0143004    0.0093114
   -3.3275864   -3.0582137   -3.2880739   -3.1652319   -3.2595842   -3.2050605
   -0.5771559   -0.4215845   -0.5502369   -0.4798793   -0.5329175   -0.5018323
    8.6550054    9.03694     8.8555822    9.009108    8.9265797    8.9896673
    column 13 to 18
    0.0060918    0.0039774    0.0026012    0.0017     0.0011116    0.0007267
   -3.2443756   -3.2205413   -3.2370826   -3.2267558   -3.233758    -3.2293072
   -0.5239947   -0.5104422   -0.5197834   -0.5139207   -0.5178794   -0.5153549
    8.9530799    8.9793862    8.9634033    8.9744763    8.9675541    8.9722428
    column 19 to 24
    0.0004752    0.0003107    0.0002031    0.0001328    0.0000869    0.0000568
   -3.2322827   -3.2303705   -3.2316378   -3.2308179   -3.2313585   -3.2310073
   -0.5170383   -0.5159543   -0.5166716   -0.516207    -0.516513    -0.5163141
    8.9692601    8.9712528    8.9699715    8.9708204    8.970271     8.9706331
    column 25 to 30
    0.0000371    0.0000243    0.0000159    0.0000104    0.0000068    0.0000044
   -3.2312381   -3.2310877   -3.2311863   -3.231122    -3.2311641   -3.2311366
   -0.5164447   -0.5163596   -0.5164154   -0.516379    -0.5164029   -0.5163873
    8.9703978    8.9705525    8.9704517    8.9705178    8.9704747    8.9705029
    column 31 to 34
    0.0000029    0.0000019    0.0000012    0.0000008
   -3.2311546   -3.2311429   -3.2311506   -3.2311456
   -0.5163975   -0.5163908   -0.5163952   -0.5163923
    8.9704845    8.9704966    8.9704887    8.9704938

após 34 iterações, erro=8.1e-07
x =

   -3.2311456
   -0.5163923
    8.9704938
```



O log decimal do erro diminui linearmente a cada iteração

2) Métodos Iterativos - Gauss Seidel

Neste método, também consideramos que cada uma das linhas do nosso sistema de equações $Ax=b$ é, na verdade, uma equação para a qual queremos encontrar a raiz.

Para o cálculo das raízes usamos exatamente o método do Ponto Fixo, aplicado a cada uma das linhas.

Como o método é iterativo, começamos com um vetor solução inicial x^0 qualquer e calculamos a solução x^1 , com a solução x^k calculamos a solução x^{k+1} e assim iterativamente, parando quando o erro relativo entre soluções subsequentes for menor que uma certa tolerância.

Como no método de Gauss Jacobi, na iteração $k+1$, usamos todos os elementos da iteração k para calcular x_1^{k+1} . No entanto, para calcular x_2^{k+1} , usamos x_1^{k+1} (que já foi calculado), e assim sucessivamente.

$$a_{11}x_1 + a_{12}x_2 + a_{13}x_3 = b_1$$

$$a_{21}x_1 + a_{22}x_2 + a_{23}x_3 = b_2$$

$$a_{31}x_1 + a_{32}x_2 + a_{33}x_3 = b_3$$

Isolando uma variável por linha temos:

$$x_1^{k+1} = \frac{1}{a_{11}}(b_1 - a_{12}x_2^k - a_{13}x_3^k)$$

$$x_2^{k+1} = \frac{1}{a_{22}}(b_2 - a_{21}x_1^{k+1} - a_{23}x_3^k)$$

$$x_3^{k+1} = \frac{1}{a_{33}}(b_3 - a_{31}x_1^{k+1} - a_{32}x_2^{k+1})$$

```
1 function x1=GaussSeidel(A,b,x_ini,tol,prt)
2     N=length(b);
3     erro=1;
4     x0=x_ini
5     sol(:,1)=x0
6     erro_vector(1,1)=erro
7     for k=2:500
8         x1(1)=(b(1)-A(1,2:N)*x0(2:N))/A(1,1);
9         for j=2:N-1
10             x1(j)=(b(j)-A(j,1:j-1)*x1(1:j-1)-A(j,j+1:N)*x0(j+1:N))/A(j,j);
11         end
12         x1(N)=(b(N)-A(N,1:N-1)*(x1(1:N-1)))/A(N,N);
13         if(norm(x1)<>0) erro=norm(x1-x0)/norm(x1) end
14         x0=x1;
15         sol(:,k)=x0
16         erro_vector(1,k)=erro
17         if erro<tol break end
18     end
19     :
20     :
26 endfunction
```


Comparação Gauss-Jacobi e Gauss Seidel

```

1 function x1=GaussSeidel(A,b,x_ini,tol,prt)
2     N = length(b);
3     erro = 1;
4     x0=x_ini
5     sol(:,1)=x0
6     erro_vector(1,1)=erro
7     for k=2:500
8         x1(1)=(b(1)-A(1,2:N)*x0(2:N))/A(1,1);
9         for j=2:N-1
10            x1(j)=(b(j)-A(j,1:j-1)*x1(1:j-1)-A(j,j+1:N)*x0(j+1:N))/A(j,j);
11        end
12        x1(N)=(b(N)-A(N,1:N-1)*(x1(1:N-1)))/A(N,N);
13        if(norm(x1)<>0) .. erro=norm(x1-x0)/norm(x1) .. end
14        x0=x1;
15        sol(:,k)=x0
16        erro_vector(1,k)=erro
17        if erro<tol .. break .. end
18    end
19    :
20    :
26 endfunction
    
```

$$\begin{aligned}
 x_1^{k+1} &= \frac{1}{a_{11}}(b_1 - a_{12}x_2^k - a_{13}x_3^k) \\
 x_2^{k+1} &= \frac{1}{a_{22}}(b_2 - a_{21}x_1^{k+1} - a_{23}x_3^k) \\
 x_3^{k+1} &= \frac{1}{a_{33}}(b_3 - a_{31}x_1^{k+1} - a_{32}x_2^{k+1})
 \end{aligned}$$

```

1 function x0=GaussJacobi(A,b,x_ini,tol,prt)
2     N = length(b);
3     erro = 1;
4     x0=x_ini
5     sol(:,1)=x0
6     erro_vector(1,1)=erro
7     for k=2:500
8         for j=1:N
9             x1(j)=(b(j)-A(j,:)*x0 + A(j,j)*x0(j))/A(j,j);
10        end
11        if(norm(x1)<>0) .. erro=norm(x1-x0)/norm(x1) .. end
12        x0=x1;
13        sol(:,k)=x0
14        erro_vector(1,k)=erro
15        if erro<tol .. break .. end
16    end
17    :
18    :
24 endfunction
    
```

$$\begin{aligned}
 x_1^{k+1} &= \frac{1}{a_{11}}(b_1 - a_{12}x_2^k - a_{13}x_3^k) \\
 x_2^{k+1} &= \frac{1}{a_{22}}(b_2 - a_{21}x_1^k - a_{23}x_3^k) \\
 x_3^{k+1} &= \frac{1}{a_{33}}(b_3 - a_{31}x_1^k - a_{32}x_2^k)
 \end{aligned}$$

Algoritmo para o Método Iterativo de Gauss Seidel

```
--> A=[8,2,4;1,11,3;5,3,10]
A =

    8.    2.    4.
    1.   11.    3.
    5.    3.   10.

--> b=[9;18;72];

--> x=inv(A)*b
x =

-3.2311475
-0.5163934
 8.9704918
```

```
--> x=GaussSeidel(A,b,[0;0;0],1e-6,%T)

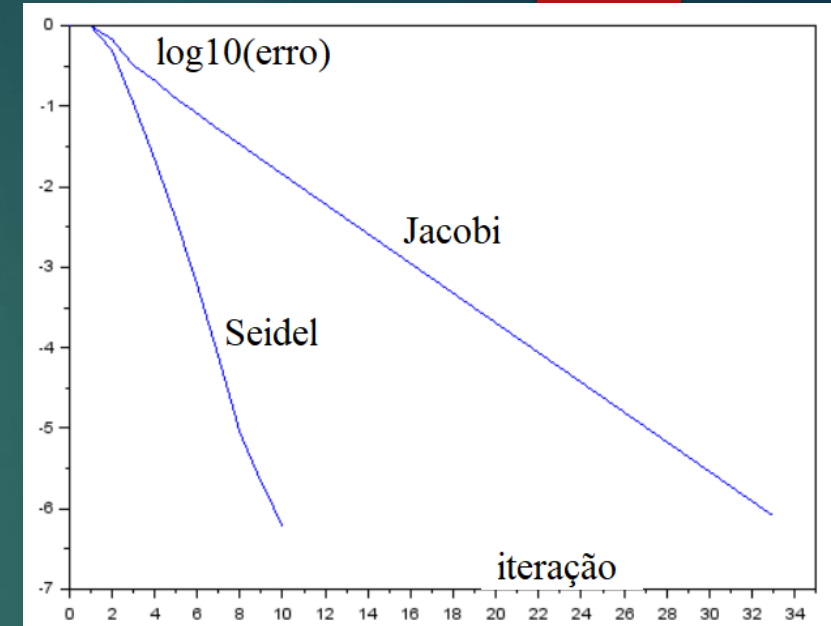
    8.    2.    4.    9.
    1.   11.    3.   18.
    5.    3.   10.   72.

"erro"
"x(1)"
"x(2)"
"x(3)"

      column 1 to 6
    1.    1.      0.497754    0.1106598    0.0222884    0.0039487
    0.    1.125    -2.3471591  -3.0782929  -3.209174   -3.2288675
    0.    1.5340909    0.165031   -0.3539925   -0.4842599   -0.5109752
    0.    6.1772727    8.3240702    8.8453442    8.9498649    8.9677263
      column 7 to 11
    0.0006037    0.0000766    0.0000089    0.0000021    0.0000006
   -3.2311194   -3.2312157   -3.2311717   -3.2311535   -3.2311487
   -0.5156418   -0.5163219   -0.5163947   -0.5163963   -0.5163944
    8.9702522    8.9705044    8.9705043    8.9704956    8.9704927

após 11 iterações, erro=6.2e-07
x =

-3.2311487
-0.5163944
 8.9704927
```



O log decimal do erro em Gauss-Seidel também diminui linearmente a cada iteração, mas com um inclinação maior, isto é: muito mais rapidamente que com o método de Gauss-Jacobi.

Convergência de Gauss-Jacobi

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & | & b_1 \\ a_{21} & a_{22} & a_{23} & | & b_2 \\ a_{31} & a_{32} & a_{33} & | & b_3 \end{bmatrix} \begin{matrix} (I) \\ (II) \\ (III) \end{matrix}$$

Vamos definir a medida α_i para a linha i:

$$\alpha_i = \sum_{\substack{j=1 \\ j \neq i}}^N \frac{|a_{ij}|}{a_{jj}}$$

O algoritmo de Gauss-Jacobi irá convergir se:

$$\max(\alpha_k) < 1$$

Convergência de Gauss-Seidel

Vamos definir a medida β_i para a linha i:

$$\beta_1 = \sum_{j=2}^N \frac{|a_{1j}|}{a_{1j}}$$

$$\beta_i = \sum_{j=1}^{i-1} \frac{\beta_{i-1} |a_{ij}|}{a_{ij}} + \sum_{j=i+1}^N \frac{|a_{ij}|}{a_{ij}}$$

$$\beta_N = \sum_{j=1}^{N-1} \frac{\beta_{i-1} |a_{ij}|}{a_{ij}}$$


O algoritmo de Gauss-Seidel i irá convergir se:

$$\max(\beta_k) < 1$$

Notar que se $\max(\beta_k) < 1$ então $\max(\alpha_k) < 1$, isto é: se Gauss_Seidel converge, então Gausss_Jacobi converge. A recíproca não é necessariamente verdadeira.

Comparação Métodos Diretos e Métodos Iterativos

- ▶ O métodos diretos sempre convergem, desde que a Matriz Característica do Sistema A não tenha determinante nulo.
- ▶ Os métodos iterativos dependem de um critério de convergência.
- ▶ Os métodos diretos usam todos os elementos da matriz para fazer os cálculos, de modo que os elementos nulos podem ser modificados durante os cálculos, o que é um problema com matrizes esparsas.
- ▶ No caso de matrizes esparsas os métodos iterativos são vantajosos, pois não modificam e pode não levar em conta os elementos nulos de uma matriz esparsa.



Exemplo de matriz esparsa

16 000 000 elementos (4000 linhas por 4000 colunas)

Somente 15 000 elementos não-nulos.